
KONSPEKT PREZENTACJI MSI2

METODY SZTUCZNEJ INTELIGENCJI W MECHANICE PŁYNÓW

Kornel Mrozowski

21 kwietnia 2021

Równania ruchu: Podstawowym wyzwaniem jest właściwe przełożenie mechanizmów fizycznych na model numeryczny. Są 3 podstawowe wzory. Równanie ciągłości mówi o relacji gęstości do prędkości przepływu. Równanie Naviera-Stokesa wiąże pewną relacją gęstość prędkość ciśnienie oraz lepkość. Równanie energii mówi o tym jak dyssypacja energii przepływu wpływa na temperaturę. Aby móc wprowadzić je do modelu uczącego się należy je zdyskretyzować oraz zlinearyzować.

Wektory i wartości własne: To co łączy mechanikę płynów i uczenie maszynowe to to, że w nawet najbardziej skomplikowanych przepływach istnieją wzorce. Dla przykładu jedno IMP zdjęcie twarzy człowieka zawiera milion informacji, ale wszystkie nie są nam konieczne potrzebne i nie trzeba budować sieci splotowej, ponieważ są dominujące wzorce, które definiują tą twarz i tak samo są wzorce które definiują pole przepływu. W 1978 roku Sirovich napisał 2 artykuły które zmieniły świat. Pierwszy z nich to tzw. twarze własne, w którym wziął bibliotekę z 1000 zdjęć ludzkich twarzy i przeprowadził na niej rozkład według wartości osobliwych aby otrzymać twarze własne lub też wektory własne tych zdjęć.

Wektory własne i wartości własne: W tym samym roku Sirovich swoją dekompozycję twarzy użył na filmach przedstawiających przepływy. Pokazał wtedy, że jeśli weźmie się wektory własne tego filmu to można otrzymać dominujące wzorce. Po pierwsze można otrzymać średnią klatkę z całego

filmu. A następnie rozkład według wartości osobliwych pozwala otrzymać kolejne wektory własne. Wzorce tego przepływu są stałe w czasie, ale ich kombinacja liniowa jest zmienna w czasie. I kiedy dodamy je do siebie dla czasu t to możemy odtworzyć oryginalny przepływ w czasie t . To jest kamień węgielny nie tylko dla przepływów dwuwymiarowych ale również dla wyższych wymiarów.

POD/PCA: Okazuje się że rozkład według wartości osobliwych można przedstawić jako sieć neuronową z jedną ukrytą warstwą z liniowymi funkcjami aktywacji. Na wejściu jest wielowymiarowe pole przepływu następnie informacja jest kompresowana w środkowej warstwie. Na końcu w dekoderyze odtwarzamy przepływ. Także kiedy trenujemy sieć to nasza funkcja straty uwzględnia różnicę pomiędzy wejściem a wyjściem, a także powinna zmuszać środkową warstwę do bycia jak najwęższą. Istnieją także bardziej skomplikowane struktury z nie liniowymi funkcjami aktywacji realizujące te same zadanie tylko lepiej. Jednym z pierwszych zastosowań głębokiego autoenkodera w 2002 roku była rekonstrukcja pola prędkości w pobliżu ściany w turbulentnym przepływie kanałowym przy użyciu ciśnienia i siły ścinania ściany (Milano i Koumoutsakos 2002).

Profil warstwy przyściennej obliczony autoenkoderem: Wyniki treningu sieci neuronowej są przedstawione na tym wykresie. Test przeprowadzono na danych nie widzianych wcześniej przez sieć w trakcie treningu ani w trakcie dekompozycji na wektory własne. I to pokazało, że model dobrze generalizuje.

Particle Image Velosimetry: *Particle Image Velosimetry* to technika służąca do mierzenia prędkości przepływu przy pomocy wiązki laserowej oraz kamery. Niestety takie pomiary mają często wiele szumów co często przeszkadza w obliczaniu prędkości. Wtedy z pomocą przychodzi nam znów dekompozycja.

Przykładowo na podstawie bazy danych zawierającej 36 ludzkich twarzy każda z nich oświetlona na 64 różne sposoby. Można uzyskać taki efekt że kiedy mamy zdjęcie przykładowej osoby zupełnie nie z tej bazy z takim wąsem to można go dzięki

autoenkoderowi rozłożyć na zdjęcie bez wąsa oraz z wąsem.

Także stosując to samo podejście do przepływów mając film przepływu z symulacji posiadający szumy, które zostały użyte na przykład dzięki *Particle Image Velosimetry* możemy rozłożyć go na obraz który tych szumów nie posiada oraz na sam szum.

W końcu po wykonaniu optymalizacji wektory własne mają dużo mniejsze szumy i dzięki temu mogą znacznie dokładniej zrekonstruować pole przepływu niż takie zaszumione wektory.

Bibliografia

[1] Leonardo da Vinci [Flow](#).

[2] Steven L. Brunton, Bernd R. Noack, and Petros Koumoutsakos [Machine Learning for Fluid Mechanics](#).